

DL26

TRACK 8

Domain Adaptation su MRI ADNI

Scanner Signatures, CycleGAN

e classificazione CN vs AD

Gruppo: EventHorizon

Membri: **Alessia Micieli** , Graziano Murabito


Repository GitHub: https://github.com/AlessiaMicieli26/EventHorizon_Track8

Obiettivo: capire quale tecnica di augmentation generalizza meglio quando si passa da Siemens + GE a Philips.


Original source




CycleGAN translated




Absolute difference




Original source




CycleGAN translated




Absolute difference




Original source




CycleGAN translated




Absolute difference




Original source




CycleGAN translated




Absolute difference



Original source



CycleGAN translated



Absolute difference



Il problema è il domain shift tra scanner MRI

Lo stesso esame può apparire diverso a seconda del produttore e delle statistiche di acquisizione.

Un modello può imparare pattern dello scanner invece che pattern della malattia.

Effetto dello scanner

Cambiano contrasto, intensità e statistiche visive anche se il contenuto anatomico è simile.

Conseguenza

Un classificatore addestrato su un dominio può degradare quando viene testato su un produttore non visto.

Sfida

Migliorare la generalizzazione cross-scanner senza perdere l'informazione diagnostica rilevante.

Train su due produttori, test su un produttore mai visto

Il task finale è la classificazione binaria CN vs AD.

TASK

Classificazione CN vs AD su MRI strutturali ADNI.

SOURCE

SIEMENS + GE Medical Systems

TARGET

PHILIPS Medical Systems

Research question

**Quale strategia di augmentation
generalizza meglio su Philips:
CycleGAN, VAE residuale o AdaIN?**

Dataset piccolo e split patient-level

Lo split a livello paziente evita leakage tra training e test.

173 volumi MRI dopo il preprocessing

52 soggetti totali

Classi diagnostiche:

- CN
- AD

Produttori considerati:

- Siemens
- GE Medical Systems
- Philips Medical Systems

Il dataset è sbilanciato verso la classe healthy:
per questo usiamo anche la macro-F1


Split	Scansioni	Soggetti	Dominio
Source train	81	24	Siemens + GE
Source val	21	7	Siemens + GE
Target adapt	36	10	Philips
Target test	35	11	Philips

Da ricordare

Il target adaptation set è separato dal target test e viene usato come dominio target non etichettato.


Una pipeline end-to-end, modulare e riproducibile

Dal preprocessing dei volumi al confronto finale tra modelli.



Il punto di partenza è una CNN source-only

Una baseline semplice serve a capire se la domain adaptation aggiunge davvero valore.



Tre blocchi convoluzionali con BatchNorm, ReLU e pooling

Adaptive average pooling, fully connected layer e dropout

Scelta leggera e praticabile, ma con il limite di usare una sola slice 2D centrale

Perché è importante?

La baseline è il controllo sperimentale: ogni tecnica di augmentation deve essere confrontata con questo modello.

Tre strategie di domain adaptation

Le tre idee sono complementari: traduzione image-to-image, firma latente dello scanner e trasferimento di stile nelle feature.

CycleGAN

Traduce immagini source verso uno stile simile a Philips usando immagini non appaiate. È potente ma può alterare dettagli utili alla classificazione.

VAE residuale

Proietta le slice in uno spazio latente e stima una scanner signature media. La generazione finale è residuale, quindi più conservativa.

AdaIN

Modifica media e deviazione standard delle feature per trasferire lo stile scanner, separando meglio contenuto anatomico e stile.

Stesso task, stessi split: cambia la strategia di augmentation

Questo rende il confronto tra modelli più leggibile e corretto.

Configurazione	Composizione training set	Totale
Source-only	81 immagini source originali	81
CycleGAN	81 originali + traduzioni source→target	162
VAE + GAN	81 originali + 81 VAE + 81 GAN	243
AdaIN + GAN	81 originali + 81 AdaIN + 81 GAN	243


Idea del confronto

Tutti i modelli sono valutati sullo stesso target test Philips: ciò permette di attribuire le differenze di performance alla diversa augmentation.

AdaIN + GAN è il modello migliore sul target Philips

Il miglioramento più importante si osserva sulla macro-F1, che è la metrica più informativa in presenza di sbilanciamento.

Modello	Accuracy	Macro-F1
Source-only	0.6571	0.3966
CycleGAN	0.4286	0.4281
VAE + GAN	0.6286	0.3860
AdaIN + GAN	0.7143	0.6500
Oracle target-supervised	0.3429	0.3066




Takeaway principale

AdaIN + GAN migliora rispetto alla baseline di +0.0571 in accuracy e soprattutto di +0.2534 in macro-F1.

Le preview mostrano differenze importanti tra le augmentation

L'osservazione qualitativa aiuta a interpretare i risultati quantitativi.

Confronto qualitativo delle augmentation scanner-domain



Cosa osserviamo?

La generazione VAE residuale tende a preservare l'anatomia e a introdurre modifiche più contenute. CycleGAN produce trasformazioni più forti, che possono essere utili ma anche rischiose.

Limite Analisi Visuale

Le preview non costituiscono una validazione clinica: servono come controllo visivo, non come prova definitiva della qualità medica delle immagini.

Figura 5: Preview qualitativa aggiornata: originale source, augmentation VAE residuale e traduzione CycleGAN.

I risultati sono promettenti, ma vanno letti con cautela

Riconoscere i limiti è parte del rigore sperimentale.

Dataset

Pochi esempi e sbilanciamento tra le classi.

Rappresentazione

Una sola slice 2D centrale invece del volume 3D.

Generazione

Augmentation non supervisionata e senza validazione clinica.

Valutazione

Mancano più seed, più ablation e rotazione dei produttori come target.

Interpretazione corretta

Il progetto non vuole proporre un sistema clinico pronto all'uso, ma una pipeline sperimentale completa e riproducibile.

Conclusioni

Messaggio principale: nella configurazione finale, AdaIN + GAN è la strategia che generalizza meglio sul target Philips.

Il domain shift da scanner è reale e può ridurre la robustezza di un classificatore MRI.

La macro-F1 è fondamentale per leggere correttamente i risultati su dati sbilanciati.

Il passo successivo è estendere la pipeline con modelli 2.5D/3D e una validazione più ampia.